

WB Техношкола

Д/З по блоку «А/Б тесты»

Артём Лосевской

Январь 2025

Хотел бы сначала сказать, что я дошёл до конца 5 раз. Всякий раз при запуску хотелось проконтролировать очень много вещей по отдельности, и в голове всплывали разные идеи, но аккуратное оформление результатов потребовало бы очень много времени.

В каком-то виде сформулировал такие выводы и наблюдения. Порядок появления идей плюс-минус хронологический :)

1. Первое моё интересное наблюдение касается тех экспериментов, для которых мы сразу имеем улучшение конверсии при любом разумном уровне значимости (=очень низкий p-value).

Кажется, что в подобных экспериментах ошибка мы можем уверенно выкатывать изменения в релиз. Что логично, поскольку вероятность случайности такого результата крайне мала.

Эксперимент b4bcad22

Бэкэнд Небольшое изменение функционала

Идет дней: 5

	Уникальных пользователей	Купивших пользователей	Конверсия в покупку
Контрольная группа	66 705	3 844	5.76%
Тестовая группа	66 626	4 082	6.13%
P-value:		0.0049	

Отменить эксперимент В релиз на всех

Аналогично и сильно значимое (то есть при очень низком p-value) ухудшение тоже в целом нет смысла долго обкатывать.

2. Пара слов про целевую метрику. Ей является, очевидно, количество купивших пользователей. Именно по ней мы тестируем H_0 : нет эффекта против H_a : эффект имеется.

Конверсия скорее вспомогательная, ведь в каждом эксперименте мы стараемся помещать в тест и контроль одинаковые по размеру подвыборки из генеральной совокупности, а потому в целом не стоит ориентироваться на неё. И тут тоже несколько слов про количества пользователей

- (a) Падение конверсии может быть при росте количества купивших пользователей, если уникальные пользователи тоже оказались чуть выше. Нужно проверять дальше.
- (b) Рост конверсии при незначительном падении количества купивших тоже может говорить, что количество уникальных в тесте вышло меньше, и потому хорошо бы ещё обкатать.

3. Дальше понял, что вывод про конверсию выше по-хорошему нам должен быть неважен: с большими сэмплами (а именно на них следует смотреть и их мы получаем, пытаюсь дальше катать тест) кажется вполне допустимым ориентироваться по значимости и по количеству купивших пользователей

Дальше о моих попытках и действиях:

1. Попытка 1.

Подглядывал и пытался понимать, что происходит. На сэмпл тогда не обращал внимания и помню, что возникли мысли про большие релизы и статистическую значимость на них. Было стойкое ощущение, что стат значимость на них явление редкое, даже при казалось бы хорошем улучшении целевых показателей.

Game Over

Your Results:

Дни в игре: 90

Итоговый доход: 716 245

Итоговая конверсия: 12.19%

Лосевской Артём Николаевич

Отправить результат

В итоге не самый худший результат среди попыток, хотя чёткой стратегии здесь не было. Просто общие идеи, к которым ещё и пришёл не сразу.

2. Попытка 2.

Тут попробовал закоммититься на строгие правила:

- Длину каждого эксперимента установил 5 дней.
- Уровень значимости установил 5 процентов.
- Эксперименты брал все подряд, и большие, и малые, особо не думаю ни о чём.

Здесь вышел не самый хороший результат, потому что очень много возможностей увеличить выручку упускалось (эффект от удачного эксперимента куммулятивный!) из-за строгих 5 дней и больших экспериментов, которые не позволяли оперативно тестировать фичи. По итогу появилась идея брать только малые или отыскивать баланс.

Game Over

Your Results:

Дни в игре: 90

Итоговый доход: 570 509

Итоговая конверсия: 7.84%

Напишите свое ФИО

Отправить результат

Появилось также понимание, что фиксировать длиной эксперимента 10 дней нет смысла, если наша цель добиться максимума выручки.

Так или иначе, получили честное увеличение относительно бейзлайна в 450.000. Тем не менее оно даёт понять, что строгое следование всем предустановленным вещам наверное очень обременительно для верхушек компании, ждущих быстрые результаты)

3. Попытка 3. "Дизайн"(кавычки неспроста) такой:

- Продолжительность 3 дня.
- Принимаем и умеренно незначимые (например, для большого релиза и на большой выборке мог принять, даже если p-value был 0.13)
- Пытаемся брать только мелкие задачи. Когда в доступных только большие, кликаем по одному и тому же боксу до мелких, остальные большие не трогаем.

Game Over

Your Results:

Дни в игре: 90

Итоговый доход: 763 221

Итоговая конверсия: 14.23%

Напишите свое ФИО

Отправить результат

4. Попытка 4.

- Продолжительность 1 день, но с оговоркой дальше.
- Сразу принимаем только значимые на 5 процентном уровне.
 - Только для больших выборок! Если выборка малая, то ждём большой и смотрим уже на ней.
- Пытаемся брать только мелкие задачи. Когда в доступных только большие, кликаем по одному и тому же боксу до мелких, остальные большие не трогаем.

Вышло 650 к, что не самый большой, но и не самый маленький результат. Эвристические подход с ожиданием больших выборок не является оптимальным. Быть может, его детектит программа, потому что такую вещь можно интерпретировать как ожидание прокраски.

Пустая строчка, чтобы латех перенёс картинку)

Game Over

Your Results:

Дни в игре: 90

Итоговый доход: 650 125

Итоговая конверсия: 9.04%

Напишите свое ФИО

Отправить результат

5. Попытка 5.

- Продолжительность 3 дня (иногда до 5+ для получения сэмплов в тритменте и контроле 50000+)
- 10 процентный уровень (выборки 50000 и больше!)
 - Сильно значимые результаты можно принять и при меньших выборках (30000 как будто норм)
- Пытаемся брать только мелкие задачи. Когда в доступных только большие, кликаем по одному и тому же боксу до мелких, остальные большие не трогаем.

Здесь вышло 630к. Вновь горе-эксперимент.

Итог.

Общий вывод будет коротенький. Игра прекрасно даёт понять, откуда берутся стимулы выкатить в прод те изменения, для которых нет чётких статистических свидетельств их эффективности. В связи с этим становится очевиден трейдофф между рандомом и следованием всем правилам проведения эксперимента. Череду благоприятных исходов для экспериментов, в которых на правила глаза закрываются, может дать большую выручку, чем эксперимент, проведенный по всем правилам. В последнем случае мы можем больше быть уверены, что выкаченные изменения действительно пойдут на пользу, хотя и дадут более умеренный прирост выручки!

Side-note.

По идее ещё может оказаться важно, какие эксперименты проводим. В идеале мы не хотим, наверное, одновременно проводить такого рода вещи (и отдел, и тип задачи совпадают).

В реальной жизни, очевидно, лучше не допускать такого, но тут мало информации о фичах. В рамках игры проверять негативный эффект от попадания таких экспериментов в активные одновременно не очень интересно и муторно.

В идеале, наверное, добиться чего-то такого в активных задачах, хотя даже так в реальной жизни может всплыть много вопросов о валидности экспериментальных результатов:

Эксперимент bebad0e9

Реклама Мелкая доработка

Идет дней: 5

	Уникальных пользователей	Купивших пользователей	Конверсия в покупку
Контрольная группа	94 948	5 384	5.67%
Тестовая группа	95 052	5 677	5.97%
P-value:	0.0049		

Отменить эксперимент В релиз на всех

Эксперимент 50656989

Реклама Мелкая доработка

Идет дней: 5

	Уникальных пользователей	Купивших пользователей	Конверсия в покупку
Контрольная группа	94 993	5 482	5.77%
Тестовая группа	95 007	5 514	5.80%
P-value:	0.7593		

Отменить эксперимент В релиз на всех

Задача 5a418940

Дизайн Небольшое изменение функционала

Небольшое изменение функционала у отдела Дизайн

Задача e037da5d

Рекомендации Мелкая доработка

Мелкая доработка у отдела Рекомендации

Задача a5612678

Поиск Мелкая доработка

Мелкая доработка у отдела Поиск

Задача c3e58cf7

Бэкэнд Большой релиз

Большой релиз у отдела Бэкэнд

Задача 42a51d3f

Реклама Мелкая доработка

Мелкая доработка у отдела Реклама